

Análisis de Usuarios de una Plataforma de Streaming

Proyecto Integrador — Minería de Datos 1 | Integrantes: [Gonzalez Shamira] — [Serrano Yonathan] | Julio 2026

1. Contexto y objetivo

El proyecto analiza un dataset de 8160 usuarios de una plataforma de streaming, con el objetivo de comprender su calidad inicial, prepararlo con decisiones justificadas, explorar patrones de comportamiento y evaluar una reducción de dimensionalidad (PCA) sobre sus variables numéricas. El alcance no incluye modelado predictivo.

2. Dataset y calidad inicial

El dataset original (*data/raw/streaming_users_dirty.json*) presentó: nulos explícitos en 3 columnas (hasta 320 registros); 126 filas duplicadas y 34 usuarios adicionales con *user_id* repetido; edades fuera de [12,100] años y minutos de consumo negativos o con código centinela 99999; tickets de soporte negativos o con códigos 99/150; categorías con grafías inconsistentes (mayúsculas, tildes, abreviaturas, inglés); y fechas de login en al menos 3 formatos distintos, algunas con componentes imposibles (ej. mes 15).

3. Decisiones de limpieza y preparación

Se eliminaron duplicados exactos y se conservó el primer registro por *user_id* repetido. Los valores fuera de rango o con código centinela en *age*, *monthly_watch_time_mins* y *customer_support_tickets* se marcaron como faltantes y se imputaron con la mediana, por ser robusta a valores extremos. Las categorías de *subscription_plan*, *country* y *favorite_genre* se normalizaron a valores canónicos mediante mapeo explícito. Las fechas se parsearon probando los formatos detectados; lo no resoluble sin ambigüedad quedó como faltante. El dataset original se preservó sin modificar; el resultado final (8000 usuarios, 0% de duplicados) se guardó en *data/processed/*, con trazabilidad completa en *logs/pipeline_log.csv*.

Paso	Retención	Nulos
Carga original	100.0%	753
Deduplicación	98.04%	753
Tratamiento de rangos numéricos	98.04%	560
Normalización de categorías	98.04%	320
Parseo de fechas y guardado final	98.04%	462

4. Hallazgos del análisis exploratorio

La edad se concentra entre 25 y 45 años; el consumo mensual presenta distribución asimétrica (mediana $\approx$ 690 min). Existe una asociación agregada entre plan de suscripción y consumo mensual: medianas de 557.6 min (Básico), 832.6 min (Estándar) y 1080.9 min (Premium), no mediada por la edad. Los tickets de soporte no muestran relación con el plan ni con la edad, y el consumo promedio por país es homogéneo (rango de $\sim$ 781 a $\sim$ 807 minutos entre los 7 países). Las tres variables numéricas presentan correlación cercana a 0 entre sí.

5. Reducción de dimensionalidad (PCA)

Se aplicó *StandardScaler* sobre *age*, *monthly_watch_time_mins* y *customer_support_tickets*, y luego PCA. Las 3 componentes explican una proporción casi idéntica de varianza (33.6%, 33.4% y 33.0%), reflejo directo de la baja correlación entre variables originales. La proyección PC1–PC2 no muestra agrupamientos por plan de suscripción. Conclusión de la etapa: no conviene reducir dimensionalidad en este subconjunto de variables sin incorporar información adicional.

6. Conclusiones y limitaciones

El plan de suscripción se asocia a mayor consumo mensual de forma pareja en todos los rangos etarios; el país y los tickets de soporte no resultan relevantes para explicar el consumo. La imputación por mediana reduce la varianza real de las variables tratadas, y $\sim$ 5.8% de los registros finales carecen de fecha de login válida. El alcance de estas conclusiones está condicionado por la información disponible y las decisiones documentadas durante el proceso. Como mejora futura, se propone incorporar variables adicionales (antigüedad de cuenta, dispositivo, cantidad de perfiles) y una fecha de alta de usuario para enriquecer el análisis.